Avance 2

Delimitación técnica, formulación y diseño experimental para la estimación de tiempos de viaje

Planeación inteligente de rutas ante interrupciones mediante técnicas de optimización e inteligencia artificial

Equipo 42 – Route Intelligence

Maestría en Inteligencia Artificial Aplicada

Luis Ángel Herrera Flores

Francisco Natanael Ortiz Martínez

Edgar Iván Rosas Gómez

Asesor / Sponsor: Dr. Gerardo Jesús Camacho González

Octubre de 2026

Índice

1. Introducción y delimitación del problema **2**

2. Arquitectura metodológica y punto de integración con el DVRPTW **3**

2.1. Punto de integración con el modelo de referencia 3

2.2. Dos momentos para la estimación de tiempos de viaje 4

3. Datos y entorno experimental **5**

3.1. Origen de los datos y selección del conjunto experimental 5

3.2. Función de PEMS-BAY dentro del experimento 6

3.3. Criterios de preparación e ingeniería de características 8

4. Formulación del entorno experimental y actualización mediante consultas guía **9**

4.1. Construcción de los tiempos de referencia 9

4.2. Consultas guía como observaciones del estado actual 10

4.3. Diseño de escenarios y selección de consultas 11

5. Compatibilidad metodológica y criterios de evaluación **12**

5.1. Compatibilidad de enfoques con la actualización rápida 13

5.2. Criterios de evaluación del componente de estimación 14

6. Alcance del avance y etapas posteriores **16**

6.1. Conclusión de preparación de datos en CRISP-ML 17

1. Introducción y delimitación del problema

El Proyecto Integrador aborda la planeación y replaneación de rutas ante interrupciones en problemas de ruteo de vehículos con ventanas de tiempo (VRPTW, por *Vehicle Routing Problem with Time Windows*). Como modelo de referencia se considera el enfoque desarrollado por Berth y Trigos para el problema de ruteo de vehículos con ventanas de tiempo ante interrupciones (DVRPTW, por *Disrupted Vehicle Routing Problem with Time Windows*), en el que los tiempos asociados con los desplazamientos entre nodos constituyen una entrada fundamental del modelo de optimización (Berth & Trigos, 2025; Berth, 2025). La calidad de esta información resulta relevante tanto para construir la planeación inicial como para evaluar y, en su caso, recuperar una operación cuando las condiciones de movilidad cambian durante la ejecución.

Dentro de esta arquitectura se distinguen dos momentos de decisión. Antes de iniciar la operación interesa anticipar las condiciones de movilidad esperadas y construir una matriz de tiempos congruente con ellas; durante la ejecución, una modificación no prevista puede volver subóptima o incluso inviable la planeación original y exigir una actualización rápida de los tiempos relevantes para los servicios pendientes. Esta distinción se desarrolla formalmente en la Sección 2.2.

En el avance anterior se analizaron distintos puntos en los que técnicas de inteligencia artificial o modelado probabilístico podrían complementar este mecanismo sin sustituir necesariamente el procedimiento de optimización. La estimación de los tiempos de recorrido se identificó como una alternativa especialmente relevante, ya que permite concentrar el uso de estas técnicas en mejorar uno de los parámetros que inciden directamente en las decisiones de ruteo.

Esta línea de trabajo adquiere importancia porque los tiempos de viaje en una red vial no son constantes. Presentan variaciones espaciales y temporales asociadas con los patrones de movilidad, la congestión y cambios en las condiciones de circulación. Una revisión sistemática reciente de la literatura organiza los problemas de predicción de tráfico en tareas temporales, espacio-temporales y origen–destino, y mantiene entre los retos centrales la escasez de datos y la representación de dependencias espacio-temporales (Du et al., 2025). En esta línea, trabajos recientes han extendido la estimación hacia ubicaciones no observadas a partir de información disponible en otros puntos de la red (Lei et al., 2024; Zhou et al., 2025), mientras que otros abordan de manera explícita la predicción de tiempos origen–destino bajo información incompleta o dispersa (Wang et al., 2025).

El presente avance mantiene los dos momentos como componentes centrales de la arquitectura general: la planeación previa del siguiente turno y la actualización durante la operación ante una disrupción. Para delimitar una primera prueba de concepto, el diseño experimental se desarrolla con mayor detalle para el segundo escenario, sin considerar la planeación previa como una aplicación secundaria. Como hipótesis de solución propuesta por el equipo, se estudiará si un modelo aprendido previamente a partir de información histórica puede utilizar un número reducido de observaciones actuales de tiempo de recorrido para estimar los tiempos requeridos por la replaneación. Estas observaciones, denominadas consultas guía dentro del diseño experimental, no tienen que coincidir con los clientes o depósitos de la instancia logística; pueden seleccionarse de forma que aporten información útil sobre diferentes zonas o corredores de la red.

En términos generales, el problema operacional de interés puede representarse como

$$K \text{ consultas actuales de tiempo de viaje} \longrightarrow \text{modelo previamente aprendido} \longrightarrow \widehat{T}^{\,\mathrm{rec}},$$

donde $\widehat{T}^{\,\mathrm{rec}}$ representa la matriz actualizada que posteriormente puede utilizarse en el mecanismo de monitoreo y recuperación. El propósito experimental será analizar cómo cambia la calidad de esta estimación conforme varían tanto el número como la selección de las consultas disponibles.

2. Arquitectura metodológica y punto de integración con el DVRPTW

2.1. Punto de integración con el modelo de referencia

El enfoque planteado en este avance conserva como núcleo de decisión el modelo de optimización utilizado para la planeación y recuperación de rutas. La incorporación de técnicas de inteligencia artificial se sitúa conceptualmente en una etapa previa, orientada a mejorar la información temporal que posteriormente puede ser utilizada por el optimizador. De esta manera, la formulación matemática del VRPTW y del DVRPTW se mantiene inicialmente sin cambios, mientras que se define el punto de integración de un componente destinado a estimar los tiempos asociados con los desplazamientos entre los nodos de la instancia.

En el modelo de referencia, la matriz

$$T = [t_{ij}]$$

contiene los tiempos asociados con las transiciones entre los nodos $i, j \in N$. Estos valores intervienen tanto en la función objetivo como en las restricciones que garantizan la consistencia temporal de las rutas (Berth, 2025; Berth & Trigos, 2025). Conforme a la convención utilizada por Berth, t_{ij} incorpora además el tiempo de servicio correspondiente al nodo de destino.

Para distinguir el componente que será objeto del diseño experimental, se denotará mediante τ_{ij} el tiempo requerido exclusivamente para el desplazamiento entre los nodos i y j. Por tanto,

$$t_{ij} = \tau_{ij} + s_j,$$

donde s_j representa el tiempo de servicio en el nodo j. Bajo esta notación, el componente asociado con las condiciones de movilidad es τ_{ij}, mientras que s_j continúa siendo un parámetro propio de la instancia logística.

En una implementación posterior, si un método de estimación produce un valor $\widehat{\tau}_{ij}$, el tiempo suministrado al modelo de optimización podría construirse como

$$\widehat{t}_{ij} = \widehat{\tau}_{ij} + s_j.$$

El conjunto de estos valores permitiría formar una matriz estimada $\widehat{T} = [\widehat{t}_{ij}]$, compatible con la estructura de entrada del modelo de referencia. La forma en que dicha matriz se obtiene depende del momento de decisión considerado. En la planeación previa interesa anticipar las condiciones esperadas para el periodo de operación, mientras que durante la ejecución interesa actualizar con rapidez la información disponible ante cambios en las condiciones de movilidad.

2.2. Dos momentos para la estimación de tiempos de viaje

La necesidad de construir o actualizar la información temporal puede presentarse en dos momentos distintos del proceso de ruteo. Aunque en ambos casos el resultado requerido por el optimizador es una matriz compatible con su formulación, los horizontes de decisión y la información disponible son diferentes.

El primer momento corresponde a la *planeación previa a la operación*. En este caso se dispone de un horizonte de tiempo mayor antes del inicio del servicio y el interés consiste en anticipar las condiciones de movilidad que prevalecerán durante el periodo de ejecución. Para ello pueden aprovecharse patrones históricos, variables temporales y, cuando se encuentren disponibles, otras fuentes contextuales relevantes. Conceptualmente, este proceso puede representarse como

$$\begin{aligned}\text{información histórica y contextual} &\longrightarrow \text{estimación de condiciones futuras} \\ &\longrightarrow \widehat{T}^{\,\text{plan}} \longrightarrow \text{VRPTW}.\end{aligned}$$

La matriz $\widehat{T}^{\,\text{plan}}$ representa una estimación de los tiempos que podrían utilizarse para construir la planeación inicial. En este escenario, el problema tiene un carácter principalmente predictivo y no se identifica con el experimento de actualización rápida desarrollado más adelante.

El segundo momento corresponde a la *recuperación durante la ejecución*. En este caso ya existe una planeación, una parte de los servicios puede haber sido completada y una modificación inesperada de las condiciones de movilidad puede requerir una nueva decisión. El tiempo disponible para obtener información actualizada es entonces mucho menor.

Para este segundo escenario se propone separar explícitamente una fase de aprendizaje previa y una fase de utilización durante la operación. A partir de una base histórica $\mathcal{D}_{\text{hist}}$ se ajustará previamente un modelo M_θ:

$$\mathcal{D}_{\text{hist}} \longrightarrow M_\theta.$$

Cuando se presente una disrupción, el objetivo será utilizar únicamente un conjunto reducido de consultas actuales de tiempo de recorrido como nueva información sobre el estado de la red:

$$K \text{ consultas actuales} \longrightarrow M_\theta \longrightarrow \widehat{T}^{\,\mathrm{rec}} \longrightarrow \text{monitoreo y recuperación.}$$

El histórico no se interpreta, por tanto, como una segunda fuente que deba consultarse exhaustivamente al momento de la disrupción; su función principal en este esquema es permitir que el modelo aprenda previamente relaciones recurrentes entre las condiciones observables y los tiempos de viaje de la red.

En la formulación de referencia, las modificaciones de los tiempos durante la ejecución se representan mediante una matriz actualizada T', utilizada para evaluar si las rutas continúan siendo factibles y, en caso necesario, activar el proceso de recuperación (Berth, 2025; Berth & Trigos, 2025). Una matriz $\widehat{T}^{\,\mathrm{rec}}$ obtenida a partir de un número reducido de consultas actuales podría proporcionar los valores requeridos por este mecanismo sin necesidad de consultar individualmente todos los pares de la instancia residual.

Los dos escenarios comparten la necesidad de transformar información sobre movilidad en tiempos utilizables por el optimizador, pero no constituyen el mismo problema. La planeación requiere anticipar condiciones futuras; la recuperación requiere actualizar rápidamente la representación de las condiciones presentes. Ambos forman parte del problema central del Proyecto. Para mantener acotada la primera validación experimental, este avance desarrolla con mayor detalle el segundo escenario, mientras que la estimación anticipada para el siguiente turno se conserva como parte de la misma arquitectura y deberá evaluarse en las etapas posteriores.

3. Datos y entorno experimental

3.1. Origen de los datos y selección del conjunto experimental

El estudio del problema planteado requiere disponer de una base histórica suficientemente amplia para caracterizar la variación temporal y espacial de las condiciones de movilidad. En una aplicación empresarial, esta información podría provenir de registros acumulados durante la operación de una flota o de servicios externos de información vial. Sin embargo, para construir un experimento reproducible y evaluar inicialmente la viabilidad del enfoque se consideraron conjuntos de datos públicos de tráfico con observaciones repetidas sobre una misma red.

Una de las principales fuentes disponibles para este tipo de información es el *Performance Measurement System* (PeMS) del California Department of Transportation (Caltrans). El sistema integra datos de detectores distribuidos en la red de autopistas de California y conserva información histórica para su análisis (California Department of Transportation, s.f.).

Para este proyecto se revisaron dos conjuntos utilizados como referencia en investigaciones sobre predicción espacio-temporal de tráfico: PEMS-BAY y METR-LA (Li et al., 2018). PEMS-BAY corresponde a una selección de sensores ubicados en el área de la Bahía de San Francisco y se

deriva de la infraestructura PeMS. METR-LA constituye un conjunto de referencia diferente, con mediciones de sensores del área de Los Ángeles. Ambos fueron utilizados por Li et al. en el trabajo que introdujo la *Diffusion Convolutional Recurrent Neural Network* (DCRNN), un modelo de aprendizaje profundo para predicción espacio-temporal de tráfico.

La variable principal disponible en estos conjuntos es la velocidad del tráfico registrada en cada sensor a intervalos regulares de cinco minutos. Por tanto, los datos no describen directamente viajes de vehículos de reparto ni tiempos entre clientes. Su utilidad para este proyecto radica en que proporcionan observaciones simultáneas y repetidas de diferentes puntos de una red durante periodos prolongados, lo que permite caracterizar patrones históricos y construir escenarios controlados de evaluación.

La versión de PEMS-BAY analizada contiene información de 325 sensores y 52 116 instantes de observación correspondientes al primer semestre de 2017, con una frecuencia nominal de cinco minutos. Cada registro puede representarse como un vector de velocidades

$$\mathbf{x}_t = \begin{bmatrix} v_1(t) & v_2(t) & \cdots & v_{325}(t) \end{bmatrix}^{\mathsf{T}},$$

de modo que el conjunto completo forma una serie temporal multivariada que describe cómo evolucionan simultáneamente las velocidades observadas en distintos puntos de la red.

Además de las series temporales de velocidad, la distribución utilizada dispone de información complementaria para identificar los sensores y representar relaciones espaciales entre ellos, incluyendo sus ubicaciones y distancias. Esta información resulta relevante para el proyecto porque permite vincular las observaciones temporales con una representación espacial de la red y proporciona los elementos necesarios para construir el entorno experimental descrito en la sección siguiente.

Como alternativa se examinó también METR-LA. Este conjunto contiene información de 207 sensores, igualmente registrada con una frecuencia de cinco minutos. La inspección preliminar de los archivos mostró una presencia considerablemente mayor de valores iguales a cero y periodos prolongados de indisponibilidad. En PEMS-BAY estos casos son sustancialmente menos frecuentes. Por esta razón, PEMS-BAY se seleccionó como conjunto principal para la primera etapa experimental, mientras que METR-LA se conserva como una posible fuente para evaluar posteriormente la robustez de los métodos frente a información incompleta.

3.2. Función de PEMS-BAY dentro del experimento

Aunque PEMS-BAY proporciona una descripción espacio-temporal rica de las condiciones de tráfico, su estructura no coincide directamente con la información requerida por una instancia de ruteo. Las observaciones corresponden a velocidades registradas en sensores, mientras que el VRPTW y el DVRPTW requieren tiempos de desplazamiento entre los nodos logísticos de la instancia. Por ello, el conjunto de datos se utilizará como laboratorio para construir y evaluar el mecanismo de estimación propuesto.

En un instante t, el estado observado puede representarse mediante el vector

$$\mathbf{x}_t = \begin{bmatrix} v_1(t) & v_2(t) & \cdots & v_{n_s}(t) \end{bmatrix}^\mathsf{T},$$

donde $v_r(t)$ representa la velocidad registrada por el sensor r y n_s corresponde al número de sensores considerados. La secuencia histórica de estos vectores constituye la base para construir, mediante el procedimiento definido en la Sección 4.1, series de tiempos de desplazamiento de referencia y observaciones históricas derivadas. Estas relaciones podrán utilizarse posteriormente para ajustar o calibrar el modelo M_θ, sin requerir que su formulación opere directamente sobre las velocidades de los sensores.

PEMS-BAY cumple además una segunda función: para cada instante de evaluación, la disponibilidad simultánea de un conjunto amplio de mediciones permite construir una referencia experimental de las condiciones de movilidad y de los tiempos de desplazamiento derivados de ellas. Esta referencia se utilizará exclusivamente para evaluar las estimaciones producidas por el modelo.

Finalmente, el conjunto de datos permitirá simular el escenario de acceso limitado a información actual. Una vez construida la referencia completa para un instante t, se seleccionará un número reducido de pares de puntos y se calcularán únicamente sus tiempos de recorrido como si correspondieran a las pocas consultas que podrían realizarse durante una disrupción. El modelo recibirá estas consultas como información actual, mientras que el resto de la referencia permanecerá oculto para fines de estimación.

De esta manera, PEMS-BAY desempeña tres funciones diferenciadas dentro del experimento: proporciona la base histórica a partir de la cual se construirán las observaciones utilizadas para el aprendizaje previo, permite obtener una referencia controlada para evaluar los resultados y hace posible simular un número limitado de consultas actuales sin depender, en esta etapa, de un servicio externo en tiempo real.

La referencia construida a partir de PEMS-BAY se utilizará como una *referencia experimental derivada* y no como una observación directa de los tiempos origen–destino reales de vehículos en la red vial. Sus valores se obtienen a partir de las mediciones disponibles y de las hipótesis utilizadas para transformar velocidades y relaciones espaciales en tiempos de desplazamiento. Por tanto, su función es proporcionar un entorno controlado y reproducible para comparar estimaciones, no representar una "verdad física" exacta de todos los tiempos de recorrido.

Finalmente, en esta etapa se parte del supuesto de que existe una base histórica suficientemente amplia para caracterizar los patrones de movilidad de la red. La construcción progresiva de dicha base a partir de la operación cotidiana de una flota, así como su validación con información proveniente de una empresa real, se consideran extensiones posteriores del proyecto.

3.3. Criterios de preparación e ingeniería de características

En el contexto de CRISP-ML, la preparación de los datos debe distinguir las características de entrada de los tiempos objetivo que se desea estimar. Las consultas guía constituyen información observable durante la operación, mientras que los tiempos de referencia de los pares logísticos se reservan como objetivos de aprendizaje o evaluación. Estos últimos no deberán incorporarse como entradas actuales del estimador.

Como complemento del diseño experimental, se proponen las siguientes características candidatas. Su inclusión definitiva deberá justificarse con pruebas sobre los periodos de entrenamiento y validación; esta propuesta no constituye evidencia de transformaciones ya ejecutadas.

Tabla 1: Características candidatas para el componente de estimación

Característica	**Construcción**	**Justificación**
Tiempo consultado	$q_k(t)$, expresado en una unidad temporal común.	Representa la información actual disponible para cada par guía.
Desviación histórica	$q_k(t) - b_k(h(t))$, donde b_k es la mediana histórica de la consulta para una franja horaria comparable.	Distingue el cambio actual del patrón recurrente del recorrido.
Razón respecto al histórico	$q_k(t)/b_k(h(t))$, únicamente cuando la referencia histórica sea positiva y válida.	Permite comparar cambios relativos entre recorridos de distinta duración.
Hora cíclica	$\sin(2\pi h(t)/24)$ y $\cos(2\pi h(t)/24)$, con $h(t)$ expresada en horas.	Representa la continuidad entre el final y el inicio del día sin imponer un salto artificial entre las 23:59 y las 00:00 horas.

Las referencias históricas b_k se calcularán exclusivamente con datos de entrenamiento. Antes de construir los tiempos se documentarán los valores faltantes, las velocidades cero y las observaciones no válidas; no se interpretará automáticamente un cero como dato ausente ni se calculará $d_e/v_e(t)$ con un denominador nulo. La regla de tratamiento y su impacto sobre los registros disponibles deberán quedar registrados.

Para métodos sensibles a la escala se evaluará la estandarización de las características mediante $z = (x - \mu_{\text{train}})/\sigma_{\text{train}}$. Las variables con varianza nula se tratarán antes de esta operación. La transformación logarítmica se considerará únicamente para variables positivas cuando su distribución y las pruebas de validación la justifiquen; no se presupondrá que todas las entradas deban seguir una distribución normal. Las estadísticas y transformaciones ajustadas en entrenamiento se conservarán para validación, prueba y utilización posterior.

La selección considerará filtros de varianza y correlación para detectar características poco variables o redundantes. Sus umbrales deberán justificarse con los resultados de validación. Como alternativa de extracción se evaluará PCA sobre las entradas estandarizadas, ajustado únicamente con entrenamiento; el número de componentes deberá fundamentarse en la varianza explicada y en la calidad de estimación. Se registrarán las dimensiones antes y después, así como el efecto

sobre el tiempo de procesamiento. La selección espacial de consultas complementa estas pruebas, pero no sustituye el análisis de las características construidas.

4. Formulación del entorno experimental y actualización mediante consultas guía

4.1. Construcción de los tiempos de referencia

Para relacionar las observaciones de PEMS-BAY con el problema de estimación de tiempos de viaje, se propone representar el entorno experimental mediante un grafo

$$G = (V, E),$$

donde V contiene los puntos utilizados para representar espacialmente la red y E las relaciones consideradas entre ellos. Esta representación se utiliza con fines experimentales y no implica que cada relación de los archivos complementarios de PEMS-BAY deba interpretarse necesariamente como un tramo vial físico directo.

Para cada conexión $e \in E$ se asociará una distancia d_e y se definirá una velocidad $v_e(t)$ a partir de las mediciones disponibles en el instante t. A partir de estos valores se obtendrá un peso temporal para la conexión,

$$w_e(t) = \frac{d_e}{v_e(t)},$$

una vez expresadas ambas variables en unidades compatibles. La regla específica para asignar una velocidad a cada conexión deberá establecerse y documentarse como una hipótesis del diseño experimental, ya que PEMS-BAY proporciona mediciones en sensores y no tiempos de recorrido directamente asociados con todas las conexiones de una red vial.

Sean $a, b \in V$ dos puntos de la red experimental y $\mathcal{P}_{ab}$ el conjunto de caminos factibles que los conectan. El tiempo de desplazamiento de referencia entre ambos se definirá mediante el camino de menor tiempo,

$$\tau_{ab}^{\mathrm{ref}}(t) = \min_{p \in \mathcal{P}_{ab}} \sum_{e \in p} w_e(t).$$

Esta formulación permite abstraer los nodos y conexiones intermedios utilizados para construir cada tiempo origen–destino. El recorrido interno puede cambiar entre distintos instantes conforme cambien los pesos temporales de las conexiones, pero para las etapas posteriores el resultado relevante es el tiempo agregado $\tau_{ab}^{\mathrm{ref}}(t)$.

Dentro de V se definirá un subconjunto $C \subseteq V$ correspondiente a los nodos logísticos para los que

el modelo de optimización requiere tiempos de desplazamiento. Para estos pares, los valores

$$\left\{\tau_{ij}^{\mathrm{ref}}(t)\right\}_{i,j\in C}$$

constituyen la referencia contra la cual se evaluarán posteriormente las estimaciones $\widehat{\tau}_{ij}(t)$. La construcción de tiempos para pares de puntos que no pertenecen a C se conserva porque dichos pares pueden utilizarse como consultas guía para obtener información sobre el estado actual de la red.

Para una primera implementación se considerará que los pesos temporales $w_e(t)$ permanecen aproximadamente constantes dentro de cada intervalo de cinco minutos del conjunto de datos. Bajo este supuesto, todos los pesos utilizados para calcular un camino corresponden al mismo estado temporal de la red. Una extensión posterior podría considerar un problema de camino mínimo dependiente del tiempo, en el que el costo de cada conexión se evalúe de acuerdo con el instante en que el vehículo ingresa a ella.

4.2. Consultas guía como observaciones del estado actual

Como hipótesis de solución propuesta por el equipo, el mecanismo de actualización investigará bajo qué condiciones un número reducido de consultas actuales permite estimar los tiempos de viaje de los pares logísticos no observados con precisión suficiente para la replaneación. Esta formulación no se asume como requisito del modelo de referencia, sino como una alternativa para reducir la cantidad de información actual que tendría que obtenerse antes de reconstruir la matriz requerida por el optimizador. Se plantea seleccionar previamente los pares consultados por su capacidad potencial para aportar información sobre diferentes zonas o corredores de la red. Esta capacidad deberá comprobarse experimentalmente, especialmente ante cambios localizados que las consultas podrían no detectar.

Sea

$$\mathcal{Q}_K = \{(a_k, b_k)\}_{k=1}^{K}$$

el conjunto de K consultas guía. Los extremos $a_k, b_k \in V$ no tienen que pertenecer al conjunto de nodos logísticos C. Para cada consulta, la información disponible durante la operación consiste únicamente en el tiempo de recorrido observado o consultado entre ambos puntos,

$$q_k(t) = \tau_{a_k b_k}(t).$$

En el entorno experimental con PEMS-BAY, cada valor $q_k(t)$ se simulará mediante el tiempo de referencia correspondiente $\tau_{a_k b_k}^{\mathrm{ref}}(t)$, calculado a partir del estado completo del instante de evaluación. Esta equivalencia se utiliza únicamente para construir un escenario controlado en

el que el modelo observa las consultas seleccionadas mientras los tiempos objetivo permanecen ocultos.

En una aplicación real, estos valores podrían obtenerse mediante un servicio externo de mapas e información de tráfico, como Google Maps, o a partir de otras fuentes operativas. El método propuesto no requiere conocer explícitamente la secuencia de calles o conexiones utilizada por el servicio para producir cada tiempo: la observación se trata como un tiempo agregado entre dos puntos conocidos.

Las consultas guía pueden interpretarse conceptualmente como *sensores virtuales agregados*: cada una resume en un único tiempo de viaje las condiciones de movilidad que afectan un recorrido de la red. Esta expresión se utiliza únicamente como una analogía conceptual; en el documento se mantiene el término *consulta guía* para evitar confundirlas con sensores físicos o con una categoría establecida de la literatura.

El modelo M_θ, ajustado previamente con información histórica, recibirá durante la operación el conjunto de observaciones actuales

$$\mathbf{q}_t = \begin{bmatrix} q_1(t) & q_2(t) & \cdots & q_K(t) \end{bmatrix}^\mathsf{T}$$

y producirá estimaciones de los tiempos de desplazamiento requeridos entre los nodos logísticos,

$$\{\widehat{\tau}_{ij}(t)\}_{i,j\in C}\,.$$

Por tanto, el problema de recuperación estudiado experimentalmente puede representarse como

$$\mathbf{q}_t \xrightarrow{M_\theta} \{\widehat{\tau}_{ij}(t)\}_{i,j\in C}\,,$$

donde el conocimiento histórico necesario para establecer las relaciones entre distintas condiciones de movilidad se encuentra incorporado previamente en los parámetros del modelo.

Esta formulación conserva la separación entre la capa de movilidad y el modelo de optimización. Una vez obtenidos los valores $\widehat{\tau}_{ij}(t)$, la incorporación de los tiempos de servicio s_j y la construcción de $\widehat{T}^{\,\mathrm{rec}}$ se realizará de acuerdo con la relación establecida en la Sección 2.

4.3. Diseño de escenarios y selección de consultas

El diseño experimental estudiará dos dimensiones relacionadas: cuántas consultas actuales se requieren y qué pares conviene consultar. Para un mismo instante de referencia se evaluarán distintos valores de K, manteniendo ocultos para el modelo los tiempos correspondientes a los pares logísticos que se desea estimar.

En una primera etapa, la selección de consultas deberá permitir comparar el valor de una cobertura

deliberada de la red frente a una selección sin criterio informativo. Por ello se considerará al menos una estrategia de referencia basada en selección aleatoria y una estrategia estructurada que busque distribuir las consultas entre distintas zonas o corredores y reducir la redundancia espacial. El objetivo inicial no es resolver un problema óptimo de localización de consultas, sino comprobar si la elección de los pares observados modifica de manera material la calidad de la estimación.

De forma esquemática, la pregunta experimental puede expresarse como

$$(K,\ \mathcal{Q}_K) \longrightarrow \text{calidad de } \{\widehat{\tau}_{ij}(t)\}_{i,j\in C}\,.$$

En una extensión posterior, la selección de consultas podría formalizarse mediante criterios de información, cobertura u observabilidad, de modo que un número reducido de observaciones proporcione la mayor cantidad posible de información sobre el estado relevante de la red. Esta extensión no se considera un requisito para la primera prueba de concepto.

Para cada instante de evaluación, PEMS-BAY permitirá construir tanto los tiempos de referencia de los pares logísticos como los valores que simulan las consultas guía. Al modelo se entregarán únicamente estas últimas, mientras que los valores de referencia se conservarán para medir el error de las estimaciones. La comparación se repetirá sobre múltiples instantes y condiciones de circulación con el fin de evitar que los resultados dependan de un único estado de la red.

5. Compatibilidad metodológica y criterios de evaluación

La estimación y predicción de información de tráfico comprende tareas con funciones diferentes dentro de un sistema de movilidad. Una revisión sistemática reciente distingue, entre otras, la predicción de series temporales, la predicción espacio-temporal y los problemas origen–destino (Du et al., 2025). Esta clasificación resulta útil para el presente proyecto porque algunos enfoques buscan anticipar condiciones futuras, otros estiman condiciones actuales utilizando información parcial y otros producen tiempos o variables asociadas con pares origen–destino. Estas funciones son complementarias, pero requieren información distinta y no deben considerarse intercambiables.

Conforme a la delimitación establecida en la Sección 2.2, el Proyecto considera como centrales tanto la estimación anticipada para la planeación previa como la actualización rápida durante la operación. En esta primera validación, el análisis metodológico se desarrolla con mayor detalle para el segundo escenario. En este contexto, la compatibilidad de una alternativa depende de su capacidad para aprovechar información histórica, incorporar observaciones actuales parciales y producir, directa o indirectamente, estimaciones de los tiempos requeridos entre los nodos logísticos. De acuerdo con la formulación de la Sección 4, la transformación de interés conserva la forma

$$\mathbf{q}_t \xrightarrow{M_\theta} \{\widehat{\tau}_{ij}(t)\}_{i,j\in C}\,.$$

5.1. Compatibilidad de enfoques con la actualización rápida

Entre los antecedentes relacionados con esta formulación se encuentran los modelos multivariados que explotan dependencias espacio-temporales aprendidas a partir de información histórica. Jenelius y Koutsopoulos proponen un modelo basado en *Probabilistic Principal Component Analysis* (PPCA) que representa correlaciones entre tiempos de viaje de una red y permite realizar predicciones condicionadas a observaciones recientes aun cuando parte de la información se encuentra ausente (Jenelius & Koutsopoulos, 2018). Cebecauer, Jenelius y Burghout desarrollan posteriormente un marco de predicción de red orientado al uso de datos de vehículos sonda escasos y valores faltantes, combinando PPCA con información local (Cebecauer et al., 2018).

La relevancia de estos trabajos para el problema planteado radica en que muestran que las condiciones observadas en diferentes partes de una red pueden presentar una estructura conjunta aprovechable para inferir información no observada directamente. Sin embargo, sus formulaciones originales no utilizan el mismo tipo de consultas origen–destino agregadas definidas en este proyecto. Por tanto, su aplicación al esquema de consultas guía requeriría una adaptación y una validación experimental; los resultados reportados en dichos trabajos no permiten concluir por sí mismos cuántas consultas serían suficientes ni cuáles deberían seleccionarse.

Investigaciones más recientes muestran que la inferencia a partir de cobertura parcial de una red continúa siendo un problema activo. Lei, Xu y Wang proponen un modelo probabilístico de difusión condicionada para estimar estados de tráfico en ubicaciones sin sensores a partir de las dependencias espacio-temporales con ubicaciones observadas (Lei et al., 2024). Por su parte, Zhou et al. desarrollan un modelo inductivo basado en grafos para predecir estados en ubicaciones no observadas y analizan su desempeño bajo distintos niveles de disponibilidad de sensores (Zhou et al., 2025). Estos enfoques constituyen evidencia contemporánea de que observaciones parciales pueden contener información útil sobre zonas no observadas, aunque trabajan con estados asociados con nodos de una red explícita y no con el esquema de consultas agregadas planteado aquí.

Otros enfoques probabilísticos proporcionan antecedentes complementarios. Hofleitner et al. utilizan una red bayesiana dinámica para representar dependencias espacio-temporales y actualizar la estimación de las condiciones de tráfico a partir de observaciones dispersas de vehículos sonda (Hofleitner et al., 2012). Este esquema resulta conceptualmente compatible con la combinación de conocimiento histórico y evidencia actual, aunque su formulación mantiene estados asociados con los enlaces de la red y requiere un procedimiento de inferencia más complejo que la representación agregada utilizada en este avance.

Zhan et al. estudian un problema distinto pero especialmente relacionado con la disponibilidad de información parcial. Su modelo estima tiempos medios de enlaces utilizando datos de viajes que contienen origen, destino, duración y distancia, sin observar directamente la trayectoria seguida; los caminos se tratan como variables latentes dentro de un modelo de mezcla bayesiano (Zhan et al., 2016). Este antecedente muestra que observaciones agregadas de viajes pueden aportar información sobre condiciones no observadas directamente en la red, aunque su metodología requiere inferencia de caminos y un volumen de observaciones distinto del escenario de pocas

consultas considerado aquí.

Un trabajo reciente se aproxima al problema desde la predicción directa del tiempo origen–destino. Wang et al. combinan reconstrucción de datos faltantes, representación adaptativa del grafo y modelado temporal para estimar tiempos OD en presencia de información vial dispersa (Wang et al., 2025). Aunque su objetivo de salida es cercano al de este proyecto, el método requiere una representación más rica de la red y no aborda específicamente la reconstrucción de una matriz a partir de un número reducido de consultas actuales.

También resulta relevante la cuestión del costo de adquirir tiempos OD desde servicios externos. Shah y Piantanakulchai estudian un esquema de aprendizaje activo que selecciona de manera iterativa qué tiempos consultar a una API para construir un conjunto de entrenamiento con menor esfuerzo de etiquetado (Shah & Piantanakulchai, 2026). Esta propuesta respalda la utilidad de seleccionar consultas cuando obtener una matriz completa es costoso, pero difiere del problema operacional considerado aquí: en ese trabajo las consultas se utilizan para incorporar nuevas etiquetas y reentrenar el modelo, mientras que en el presente diseño las consultas se obtienen después del entrenamiento y se usan como evidencia actual para producir $\widehat{T}^{\,\mathrm{rec}}$ sin reentrenamiento en el momento de la disrupción.

También existen métodos cuya función se encuentra en otras etapas del proceso. Modelos espacio-temporales sobre grafos, como DCRNN, están orientados principalmente a predecir la evolución futura de variables de tráfico a partir de series históricas distribuidas sobre una red (Li et al., 2018). Por ello, resultan más directamente relacionados con el problema de planeación previa que con la actualización mediante unas pocas consultas actuales. En sentido diferente, Gentile et al. estudian la generación eficiente de tiempos punto a punto cuando la información dinámica de la red ya se encuentra disponible (Gentile et al., 2020). Su propuesta es, por tanto, complementaria a la estimación del estado actual, pero no sustituye el mecanismo que debe inferir información a partir de observaciones limitadas.

En conjunto, estos antecedentes respaldan la viabilidad de aprovechar dependencias históricas y observaciones parciales para estimar información de movilidad, pero también muestran que las alternativas disponibles resuelven subproblemas diferentes. En esta etapa no se selecciona un método definitivo. La comparación e implementación de modelos candidatos deberá realizarse posteriormente sobre la formulación y los escenarios definidos en este avance, manteniendo como requisito que la información nueva necesaria durante la recuperación se limite al conjunto de consultas actuales disponible.

5.2. Criterios de evaluación del componente de estimación

La evaluación del mecanismo propuesto debe determinar si las estimaciones obtenidas a partir de un conjunto reducido de consultas representan con suficiente precisión los tiempos de desplazamiento que permanecerían ocultos para el modelo. Para ello, los valores estimados se compararán con los tiempos de referencia construidos mediante el procedimiento de la Sección 4.

Sea $\mathcal{T}_{\text{test}}$ el conjunto de instantes reservados para evaluación. Para evitar que los resultados reflejen información utilizada durante el ajuste del modelo, los periodos destinados a entrenamiento y prueba deberán mantenerse separados respetando el orden temporal de los datos. En la primera evaluación se considerará la matriz completa de pares ordenados de nodos $i, j \in C$, con $i \neq j$. Bajo este criterio, el error absoluto medio de los tiempos de desplazamiento podrá calcularse como

$$\text{MAE}_\tau = \frac{1}{|\mathcal{T}_{\text{test}}|\,|C|(|C|-1)} \sum_{t \in \mathcal{T}_{\text{test}}} \sum_{\substack{i,j \in C \\ i \neq j}} \left| \widehat{\tau}_{ij}(t) - \tau_{ij}^{\text{ref}}(t) \right|.$$

De manera complementaria se utilizará la raíz del error cuadrático medio,

$$\text{RMSE}_\tau = \sqrt{\frac{1}{|\mathcal{T}_{\text{test}}|\,|C|(|C|-1)} \sum_{t \in \mathcal{T}_{\text{test}}} \sum_{\substack{i,j \in C \\ i \neq j}} \left(\widehat{\tau}_{ij}(t) - \tau_{ij}^{\text{ref}}(t) \right)^2}.$$

El MAE permitirá interpretar directamente la magnitud promedio de los errores en unidades de tiempo, mientras que el RMSE otorgará mayor peso a errores de gran magnitud que podrían resultar especialmente relevantes para una decisión de replaneación. Las métricas se aplicarán sobre los tiempos de desplazamiento τ_{ij}, ya que los tiempos de servicio s_j permanecen como parámetros de la instancia logística y se incorporan posteriormente al construir $\widehat{T}^{\,\text{rec}}$.

El número de consultas K no se considerará una métrica de error, sino una variable del diseño experimental. Para cada alternativa se analizará cómo cambia la precisión al modificar K y la composición de $\mathcal{Q}_K$. Esto permitirá estudiar por separado el efecto de disponer de más observaciones y el efecto de seleccionar pares potencialmente más informativos. Conforme al diseño establecido en la Sección 4.3, las comparaciones deberán realizarse sobre los mismos instantes y tiempos objetivo para evitar que diferencias en las condiciones de circulación se confundan con diferencias atribuibles a las consultas seleccionadas.

Además de la precisión, se registrará el tiempo requerido por el modelo para producir las estimaciones una vez disponibles las consultas guía. Este tiempo corresponde a la etapa de inferencia y debe distinguirse del tiempo que, en una aplicación real, pudiera requerir la obtención de información desde un servicio externo. El entorno experimental con PEMS-BAY permite controlar el primero y estudiar el efecto de K, pero no pretende reproducir la latencia de una plataforma comercial de información vial.

Para determinar si las observaciones actuales aportan información adicional respecto de los patrones recurrentes de la red, los resultados se compararán también con una referencia histórica sencilla construida sin utilizar las consultas del instante de evaluación, por ejemplo mediante valores característicos para periodos temporales comparables. Esta referencia permitirá distinguir la mejora atribuible a la incorporación de información actual de aquella que podría obtenerse únicamente a partir del comportamiento histórico. Esta comparación incluirá el caso sin consultas actuales ($K = 0$). La elección de características, transformaciones y parámetros utilizará un

periodo de validación separado del conjunto final de prueba. Para cada combinación de K y $\mathcal{Q}_K$, se documentará qué entradas recibe el modelo y si requiere un ajuste independiente; los pares consultados deberán conservar una identidad y un orden explícitos.

La evaluación se repetirá sobre múltiples instantes y condiciones de circulación. Por tanto, además de los valores agregados de MAE y RMSE, deberá examinarse la dispersión de los errores para identificar si el desempeño se mantiene estable o se deteriora en determinados estados de la red. En esta etapa el objetivo es caracterizar el desempeño del componente de estimación, no determinar todavía el efecto final sobre las rutas generadas por el DVRPTW.

La evaluación operacional completa corresponderá a la integración posterior con el modelo de optimización. En esa etapa podrán analizarse, entre otros aspectos, la factibilidad de las rutas, la calidad de la solución, el costo resultante y el tiempo total de respuesta. Mantener separados ambos niveles de evaluación permitirá determinar primero si el mecanismo de consultas guía produce una representación suficientemente precisa y rápida de los tiempos de viaje y, posteriormente, si dicha representación se traduce en mejores decisiones de planeación o replaneación.

La mejora predictiva no se interpretará por sí sola como una mejora integral del sistema. Una vez incorporadas las estimaciones al modelo de ruteo, la evaluación deberá considerar también efectos sobre los actores involucrados y sobre criterios transdisciplinarios relevantes, tales como cumplimiento de ventanas de servicio, tiempo de operación de los conductores, utilización de recursos, costos y estabilidad de la operación. De esta forma, las métricas de error de la capa de estimación y las métricas operacionales del modelo de ruteo se mantendrán diferenciadas, pero vinculadas dentro de la evaluación final.

6. Alcance del avance y etapas posteriores

El presente avance deja establecida la formulación necesaria para estudiar la actualización de los tiempos de viaje utilizados por el modelo de ruteo. Se definieron el punto de integración con el VRPTW/DVRPTW de referencia, el papel de PEMS-BAY como entorno experimental, la construcción de tiempos de referencia, el esquema de consultas guía y los criterios con los que podrá evaluarse posteriormente la precisión y rapidez del componente de estimación.

El alcance actual no comprende todavía la selección definitiva ni la implementación comparativa de un modelo de inteligencia artificial, ni la evaluación de su efecto sobre las rutas generadas por el optimizador. La revisión metodológica permite identificar enfoques compatibles con la formulación propuesta, pero su implementación y comparación experimental corresponderán a etapas posteriores del proyecto.

En los siguientes avances se implementará o reproducirá primero el método de referencia para la optimización y recuperación de rutas. Posteriormente podrán implementarse y compararse alternativas para la estimación de tiempos de viaje utilizando los escenarios y métricas definidos en este documento. Una vez seleccionada una alternativa suficientemente precisa y rápida, sus estimaciones $\widehat{\tau}_{ij}(t)$ podrán incorporarse a $\widehat{T}^{\,\mathrm{rec}}$ para analizar su efecto sobre la factibilidad, calidad

y tiempo de respuesta del proceso de replaneación.

La predicción de condiciones futuras para la planeación previa permanece como uno de los dos componentes centrales de la arquitectura propuesta, aunque su validación experimental detallada se desarrollará en una etapa posterior a la primera prueba de concepto enfocada en actualización rápida. Asimismo, la incorporación de eventos contextuales mediante representaciones semánticas, la validación con información operativa de una empresa, la utilización de servicios externos de tráfico en tiempo real y el desarrollo de estrategias más avanzadas para seleccionar las consultas guía se consideran extensiones posteriores de la implementación experimental.

6.1. Conclusión de preparación de datos en CRISP-ML

La fase de preparación de datos queda delimitada por la conversión de las mediciones de movilidad en tiempos de referencia, la identificación de entradas disponibles durante la operación y los criterios de construcción, escalamiento y selección o extracción de características. La separación entre entradas y objetivos, junto con el ajuste del procesamiento únicamente sobre entrenamiento, busca reducir el riesgo de fuga de información y de una evaluación excesivamente favorable.

Para concluir esta fase será necesario ejecutar el procesamiento y documentar la calidad de los datos, las distribuciones antes y después de las transformaciones, las características conservadas y la reducción obtenida. El diseño aquí presentado no permite afirmar todavía mejoras de rendimiento ni de convergencia. En CRISP-ML, el paso al modelado deberá apoyarse en un conjunto preparado de forma reproducible y en evidencia de que las decisiones adoptadas son compatibles con la información disponible durante la operación.

Referencias

Berth, M. O., & Trigos, F. (2025). A Transdisciplinary Framework for Handling Disruptions in Vehicle Routing with Customer Time Windows. En F. Trigos et al. (Eds.), *Transdisciplinarity for a Better World* (pp. 201–210). https://doi.org/10.3233/ATDE251092

Berth, M. O. (2025). *Transdisciplinary Approach to Disruptions in Vehicle Routing Problems* [Tesis de maestría]. Reutlingen University. Written at Instituto Tecnológico y de Estudios Superiores de Monterrey.

California Department of Transportation (s.f.). *Performance Measurement System (PeMS) Data Source*. Consultado el 9 de octubre de 2026. https://dot.ca.gov/programs/traffic-operations/mpr/pems-source

Cebecauer, M., Jenelius, E., & Burghout, W. (2018). Integrated Framework for Real-Time Urban Network Travel Time Prediction on Sparse Probe Data. *IET Intelligent Transport Systems, 12*(1), 66–74. https://doi.org/10.1049/iet-its.2017.0113

Du, K., Guo, X., Li, L., Song, J., Shi, Q., Hu, M., & Fang, J. (2025). Traffic Prediction in

Time Series, Spatialtemporal, and OD Data: A Systematic Survey. *Journal of Traffic and Transportation Engineering (English Edition), 12*(3), 666–700. https://doi.org/10.1016/j.jtte.2025.03.001

Gentile, G., Meschini, L., Tiddi, D., Fiorani, A., & Attanasi, A. (2020). Fast Estimation of Point-to-Point Travel Times for Real-Time Vehicle Routing. *Transportation Research Procedia, 47*, 401–408. https://doi.org/10.1016/j.trpro.2020.03.115

Hofleitner, A., Herring, R., Abbeel, P., & Bayen, A. M. (2012). Learning the Dynamics of Arterial Traffic From Probe Data Using a Dynamic Bayesian Network. *IEEE Transactions on Intelligent Transportation Systems, 13*(4), 1679–1693. https://doi.org/10.1109/TITS.2012.2200474

Jenelius, E., & Koutsopoulos, H. N. (2018). Urban Network Travel Time Prediction Based on a Probabilistic Principal Component Analysis Model of Probe Data. *IEEE Transactions on Intelligent Transportation Systems, 19*(2), 436–445. https://doi.org/10.1109/TITS.2017.2703652

Lei, D., Xu, M., & Wang, S. (2024). A Conditional Diffusion Model for Probabilistic Estimation of Traffic States at Sensor-Free Locations. *Transportation Research Part C: Emerging Technologies, 166*, 104798. https://doi.org/10.1016/j.trc.2024.104798

Li, Y., Yu, R., Shahabi, C., & Liu, Y. (2018). *Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting*. International Conference on Learning Representations.

Shah, S. M. T., & Piantanakulchai, M. (2026). Ensemble Machine Learning for Travel Time Prediction: An Active Learning-Assisted Approach. *Results in Engineering, 29*, 108712. https://doi.org/10.1016/j.rineng.2025.108712

Wang, R., Guo, Q., Dai, S., Deng, L., Xiao, Y., & Jia, C. (2025). An OD Time Prediction Model Based on Adaptive Graph Embedding. *Physica A: Statistical Mechanics and its Applications, 657*, 130217. https://doi.org/10.1016/j.physa.2024.130217

Zhan, X., Ukkusuri, S. V., & Yang, C. (2016). A Bayesian Mixture Model for Short-Term Average Link Travel Time Estimation Using Large-Scale Limited Information Trip-Based Data. *Automation in Construction, 72*, 237–246. https://doi.org/10.1016/j.autcon.2015.12.007

Zhou, Q., Zhang, Y., Makridis, M. A., Kouvelas, A., Wang, Y., & Hu, S. (2025). MoGERNN: An Inductive Traffic Predictor for Unobserved Locations. *Transportation Research Part C: Emerging Technologies, 174*, 105080. https://doi.org/10.1016/j.trc.2025.105080